

Predicting solar chromospheric emission from magnetograms using neural networks

Image to image translation
using Deep Learning

BACHELORARBEIT

ausgearbeitet von

Muhammed KURNASAN

zur Erlangung des akademischen Grades
BACHELOR OF SCIENCE (B.Sc.)

vorgelegt an der

TÜRKISCH-DEUTSCHEN UNIVERSITÄT
FAKULTÄT FÜR INGENIEURWISSENSCHAFTEN

im Studiengang
INFORMATIK

Betreuer: Dr. Emre Işık
Türkisch-Deutsche Universität

Istanbul, im 15 Juli 2022

Inhaltsverzeichnis

1	Einleitung	4
2	Fundamentals	6
2.1	Deep Neural Networks	6
2.2	Convolutional Neural Networks (CNNs)	6
2.2.1	Konvolutionalsschichten	7
2.2.2	Pooling Schichten	8
2.2.3	Dekonvolutionsschichten	8
2.2.4	Unpooling Schichten	9
2.2.5	U-Net und Voll-Konvolutionale Neurale Netze	10
2.3	Generative Adversarial Networks (GANs)	11
2.3.1	GAN-Trainingsalgorithmus	12
2.3.2	Conditional Generative Adversarial Networks (cGAN)	12
2.3.3	Pix2Pix	12
2.3.4	Probleme der GANs	13
3	Der Stand der Technik	16
3.1	Das Nutzen von GANs in anderen wissenschaftlichen Felder	16
3.2	Verwendung von GANs und CNNs in ähnlichen Solarstudien	17
4	DataSet	18
4.1	Daten Suche	18
4.2	Daten Analyse	19
4.3	Daten Bearbeitung	20
	Abbildungsverzeichnis	22
	Tabellenverzeichnis	23
	Literaturverzeichnis	24

Kurzfassung

In den letzten Jahren beinhalten neue wissenschaftliche Arbeiten neue Techniken zur Erschließung des Potenzials zur Lösung hochkomplexer Probleme, die sonst sehr kostspielige oder nahezu unmögliche Lösungen erfordern würden, wie z. B. die Bild-zu-Bild-Übersetzung, indem Deep-Learning-Algorithmen genutzt werden, um Probleme wie den Mangel an Daten zu umgehen, mit Techniken wie Convolutional Neural Networks und Generative Adversarial Networks. Ähnlich wie bei diesen Lösungen versuche ich, synthetische Daten mit einer Variante von GANs zu erstellen, um Sonnenmagnetogramme zur Erzeugung entsprechender AIA 1600-Bilder der Sonne zu verwenden, die Emissionen aus der Sonnenchromosphäre zeigen und sich in Bereichen unterschiedlicher Farbe zeigen.

Abstract

Recent works have involved new techniques in unlocking the potential of solving problems of high complexity, that would otherwise need very costly or nearly impossible solutions, like Image-to-image translation, by taking advantage of Deep Learning algorithms to get around problems like the lack of data or, involving Convolutional Neural Networks and Generative Adversarial Networks. Similar to those solutions, I try to create synthetic data using a variant of GANs for using solar magnetograms for generating correspondent AIA 1600 Images of the Sun, which show emission from the solar chromosphere, revealing themselves in areas of different colour.

1 Einleitung

Die Sonne ist der Stern, der unserem Heimatplaneten am nächsten liegt, und damit unser einziger lokaler Stern in unserer Nachbarschaft. In der Milchstraßengalaxie ist seine Existenz eine der wichtigsten Voraussetzungen, nicht nur für die Entstehung und Erhaltung unserer Planeten in ihren Umlaufbahnen, sondern auch dafür, dass jegliche Art von Leben überhaupt existieren und sich im Laufe der Zeit erhalten kann. Obwohl es sich um die kälteste Schicht der Sonne handelt, finden über der Photosphäre Sonnenphänomene statt, die die Helligkeitsverteilung der Sonnenoberfläche beeinflussen, wie Sonnenflecken und Fackeln.

Es besteht ein starker Zusammenhang zwischen der Helligkeit eines Sonnenbereichs und seiner magnetischen Aktivität. Diese Beziehung zeigt sich in fast allen Formen von Sonnenphänomenen wie Sonnenflecken. Sonnenflecken erscheinen vorübergehend paarweise oder einzeln als dunkle Flecken auf der Sonnenoberfläche. Das starke Magnetfeld verhindert, dass Wärme die Oberfläche dieser Regionen erreicht, was für einen dramatischen Helligkeitsunterschied verantwortlich ist. Facula-Bereiche werden häufig an den Rändern der Sonne beobachtet und sind magnetische Bereiche mit einem Magnetfeld, das in kleinen Bündeln konzentriert ist und heller aussieht.

Das Royal Observatory Greenwich in London führt seit 1874 eine detaillierte Aufzeichnung der Größe und Position von Sonnenflecken und entdeckte den Sonnenfleckenzyklus, in dem sie die Häufigkeit, Position und Intensität von Sonnenflecken entdeckten. Dank des Solar Dynamic Observatory, das mit Auflösungen von bis zu 4096×4096 die volle Sonne im Ultraviolett bei 1600 /Å mit einer Pixelgröße von 0,6 Bogensekunden aufnimmt, stehen jetzt jedoch neue, hochpräzise und viel detailliertere Bilder von der Sonne zur Verfügung. B. AIA 1600-Bilder, die chromosphärische Aktivität zeigen.

Wie bereits erwähnt, spielen die Magnetfeldlinien und ihre unterschiedliche Stärke und Richtung durch die Sonnenoberfläche die größte Rolle, die sich in Sonnenphänomenen und bipolarer Aktivität, wie in Sonnenfleckenpaaren, offenbart und schließlich zur Manifestation des Helligkeitsunterschieds führt. Jede Ecke der Sonne. Auf der anderen Seite vereinfachen maschinelle Lernalgorithmen häufig den Code und erzielen eine bessere Leistung als herkömmliche Ansätze, wenn es um Probleme geht, die viele Optimierungen oder lange Listen von Regeln in herkömmlichen Lösungsmethoden erfordern. Und sowohl Deep-Learning-Convolutional- als auch Generative-Adversarial-Networks-

1 Einleitung

Neuronale Netzwerke haben die Fähigkeit, hochpräzise Modelle der Bildklassifizierung und die Generierung von tadellos genauen Imitationen von Bildern zu erstellen, grundlegend weiterentwickelt.

Eine unüberwachte Modellierungsmethode für maschinelles Lernen zum Erkennen von Mustern in Eingabedaten und Verwenden des Ergebnisses zum Synthetisieren neuer Daten, die den ursprünglichen Daten nicht unterscheidbar ähnlich sind, wird als generative Modellierung bezeichnet. Eine neue clevere Trainingstechnik, die ein solches generatives Modell beinhaltet, hat Forschern geholfen und in vielen Bereichen revolutioniert, indem sie synthetische Daten ausgibt, die dem Trainingsdatensatz vollkommen ähnlich sind, genannt Generative Adversarial Networks.

Aufgrund des Musters und der Beziehung zwischen magnetischer Aktivität und der Helligkeit jedes Bereichs der Sonne ohne die Fähigkeit einer fehlerfreien klaren Gleichung, die Beziehung zu modellieren, kann ein generatives maschinelles Lernmodell entwickelt werden, um Magnetogramme zu verwenden, um eine genaue Annäherung der Helligkeitsverteilung vorherzusagen über die Sonnenoberfläche und ermöglicht es Wissenschaftlern, mit AIA 1600-Bildern zu arbeiten, die von den AIA 1600-Bildern des SDO kaum zu unterscheiden sind.




Abbildung 1.1: Foto von der Sonne-am Links AIA1600 und am Rechts Magnetogram HMIB. [NASA]

2 Fundamentals

Es gibt einige Begriffe, die näher erläutert werden müssen:

2.1 Deep Neural Networks

Tiefe neuronale Netze sind eine Lösung des maschinellen Lernens, die hilft, komplexe Aufgaben des maschinellen Lernens zu bewältigen, die normale -oberflächliche-künstliche neuronale Netze normalerweise nicht lösen können oder wo gewöhnliche neuronale Netze eine kostspielige Lösung bieten. Sie haben eine viel höhere Anzahl von verborgenen Schichten, die auch eine höhere Anzahl von Neuronen enthalten, manchmal Hunderttausende von Neuronen.

2.2 Convolutional Neural Networks (CNNs)

Convolutional Neural Networks sind eine Deep Neural Network-Variante, die nicht nur in Anwendungen der Computer Vision, sondern auch in anderen Bereichen wie der Verarbeitung natürlicher Sprache verwendet wird. Die Verwendung von Faltungsschichten (Konvolutionsschichten) in dieser Art von neuronalen Netzwerken hebt die Grenzen des Potenzials auf, jede Art von gesuchten Mustern in Bildern zu erkennen, und dies wird in CNNs komplexen Aufgaben in Anwendungen wie Gesichtserkennung, Handschrifterkennung, Objekt- oder Strukturerkennung usw. demonstriert. CNNs haben in all diesen Bereichen eine Revolution vollzogen. Convolutional Neural Networks funktionieren auf eine Weise, die das neuronale Netzwerk größtenteils davon abhält, sich Hindernissen zu stellen, mit denen traditionelle neuronale Deep-Learning-Netzwerke konfrontiert sind, wie beispielsweise das Problem des verschwindenden Gradienten.

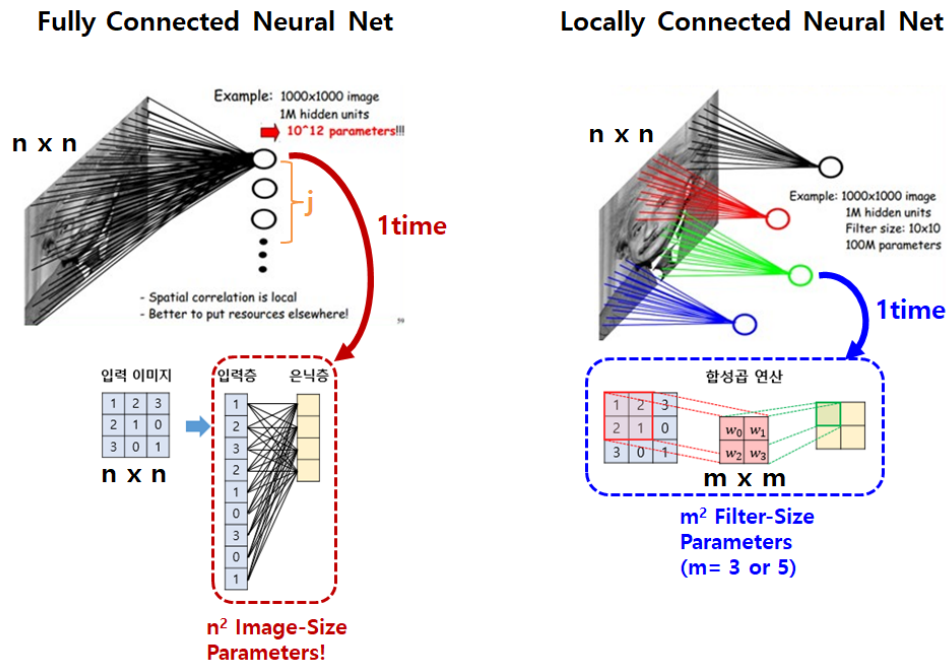


Abbildung 2.1: ..

2.2.1 Konvolutionsschichten

Dies ist die Hauptstruktur eines Convolutional Neural Network. In dieser Schicht findet ein Lernprozess statt, indem die Parameter der Filter – Kernel, die oft kleiner sind als das Originalbild – optimiert werden. Jeder Filter wird auf das gesamte Bild angewendet (gleitet) (gefaltet) - nach Höhe und Breite - und erstellt eine Aktivierungskarte, indem bei jedem Gleiten das Skalarprodukt zwischen jedem Paar Komponenten des Filters und dem Wert des Bildes bei der jeweiligen Punkt berechnet wird.




Abbildung 2.2: Ein Beispiel von einer Konvolution auf eine Stelle in Matrix

2.2.2 Pooling Schichten

Pooling ist ein weiterer wichtiger Prozess in CNNs und könnte als Downsampling-Verfahren ausgearbeitet werden. Es gibt mehrere Funktionen, die Pooling implementieren, die nicht linear sind, aber das durchschnittliche Pooling ist weit verbreitet. Es setzt den Wert in jeder Unterregion in einer Merkmalskarte auf den Durchschnittswert davon zurück, die Merkmalskarte wird in gleiche Unterregionen von Quadraten oder Rechtecken partitioniert. Diese Quadrate oder Rechtecke werden mit einem Pooling ausgewählt, was sehr nützlich ist, um die Berechnungskosten in CNNs zu senken.




Abbildung 2.3: Ein Beispiel von eine Pooling Operation, nämlich MaxPooling

2.2.3 Dekonvolutionsschichten

Die Dekonvolutionsoperation ist eine Upsampling-Technik, die das Verbindungsmuster beibehält, während sie auch Feature-Maps upsampelt, und ist im Grunde eine Operation, die den Prozess einer Faltungsschicht umkehrt.

Die Entfaltungsschichten verwenden effektiv faltungsähnliche Techniken mit vielen Filtern, um die Eingabe zu verstärken und zu verdichten. Im Gegensatz zu früheren Skalierungstechniken hat die Dekonvolution trainierbare Parameter. Die Gewichte der Dekonvolutionsschichten werden während des Netzwerktrainings kontinuierlich aktualisiert und verbessert. Ein Faltungskern mit einem Einheitsschritt wird nach dem Einfügen von Nullen zwischen den aufeinanderfolgenden Neuronen im rezeptiven Feld der Eingabeseite angewendet. Hyeonwoo Noh [2015]




Abbildung 2.4: Ein Beispiel von eine Deconvolution Operation

2.2.4 Unpooling Schichten

Unpooling ist der umgekehrte Vorgang des Poolings, der die Idee des Poolings übernimmt. Eine Variante des Unpooling wäre die Max-Up-Pooling-Operation, die als die Rückkehr von Max-pooling ist, wo Max-pooling nur die größte Antwort aus allen unterteilten Regionen der Merkmalskarte nimmt. So, gibt Up-Max-Pooling die selbe Werte Mehrmals, je wie die gewünschte Größe ist.




Abbildung 2.5: Konvolution, pooling, Dekonvolution, und unPooling

2.2.5 U-Net und Voll-Konvolutionale Neuronale Netze

Voll-Konvolutionale Neuronale Netze unterscheiden sich grundlegend von anderen CNNs dadurch, dass sie keine dichten Schichten einzelner Neuronen haben.

Ein Beispiel von diesen sind die Variante von U-net. U-net fügt zusätzliche Schich-




Abbildung 2.6: eine Voll-Konvolutionale Neuronale Netzwerk

ten zu einem Netzwerk hinzu, das aus zwei Teilen besteht, einem Downsampling-Netzwerk und einem Upsampling-Netzwerk. Die Upsampling-Operatoren werden anstelle von Pooling-Operationen verwendet, was dazu führt, dass die Auflösung der Ausgabe erhöht wird, anstatt sie auf eine kleinere Auflösung zu bringen, schließlich ein Bild in derselben Dimension wie das Originalbild rekonstruiert und die Ergebnisse darauf gespeichert und angezeigt werden. Unter Verwendung dieser Daten als Grundlage kann die Upsampling-Seite des Netzwerks anschließend lernen, eine präzise Ausgabe zusammenzustellen. Ronneberger et al. [2015]

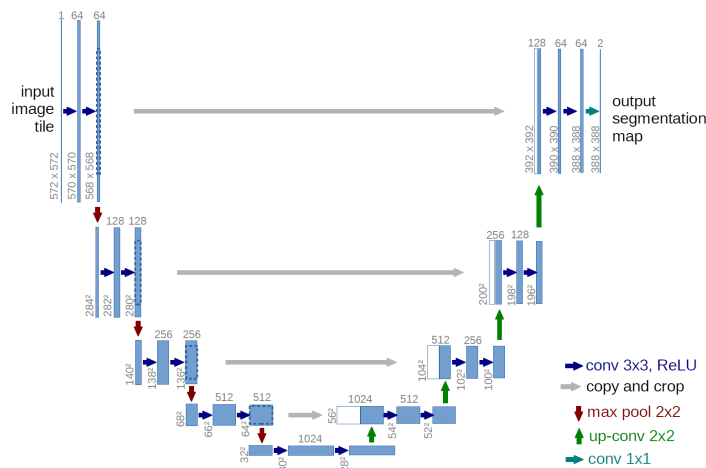


Abbildung 2.7: Die Architektur von U-Net

Es gibt andere Unterstrukturen, die an CNNs beteiligt sind, aber diese beiden sind die Hauptstrukturen.

2.3 Generative Adversarial Networks (GANs)

Generative Adversarial Networks sind eine Mischung aus zwei verschiedenen Netzwerken, die konträr zusammenarbeiten, um zu lernen, präzisere Ergebnisse zu erzielen. Es gibt zwei Netzwerke, die als Komponenten der Generative Adversarial Networks dienen: ein Generatornetzwerk, das normalerweise ein Deep Deconvolutional Neural Network ist, und ein Diskriminatornetzwerk, das normalerweise ein Deep Convolutional Neural Network ist. Generative Adversarial Networks sind eine Mischung aus zwei verschiedenen Netzwerken, die konträr zusammenarbeiten, um zu lernen, präzisere Ergebnisse zu erzielen. Es gibt zwei Netzwerke, die als Komponenten der Generative Adversarial Networks dienen: ein Generatornetzwerk, das normalerweise ein Deep Deconvolutional Neural Network ist, und ein Diskriminatornetzwerk, das normalerweise ein Deep Convolutional Neural Network ist.

Der Generator G_θ ist ein gerichtetes latentes Netzwerk, das Abtastwerte x aus z erzeugt, und das Diskriminatornetzwerk D_ϕ dient als eine Funktion, die Abtastwerte vom Generator unterscheidet. Beide Netzwerke trainieren mit Backpropagation für unterschiedliche Ziele. Das Trainingsziel von t besteht darin, Stichproben zu erstellen, die echten Datensatzstichproben für D_ϕ ähneln, wodurch die Fehlerrate von D_ϕ maximiert wird. Der Generator ist ein gerichtetes latentes Netzwerk, das Abtastwerte x aus z erzeugt, und das Diskriminatornetzwerk dient als eine Funktion, die Abtastwerte vom Generator unterscheidet.

Beide Netzwerke trainieren mit Backpropagation für unterschiedliche Ziele. Das Trai-

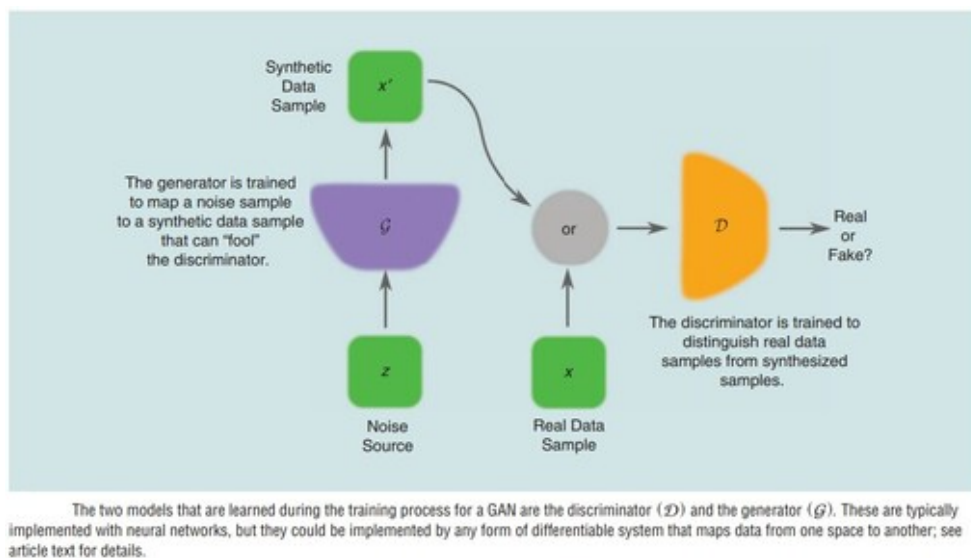


Abbildung 2.8: Die Architektur von GAN

ningsziel von t besteht darin, Stichproben zu erstellen, die echten Datensatzstichproben für D_ϕ ähneln, wodurch die Fehlerrate von D_ϕ maximiert wird.

Mit anderen Worten, G_θ erstellt synthetisierte Samples für D_ϕ und versucht, es zu täuschen. D_ϕ wird mit realen Daten gefüttert, um eine akzeptable hohe Genauigkeit beim Markieren künstlicher Samples von G_θ zu erreichen, während G_θ basierend auf hohen Fehlerraten von D_ϕ trainiert, also erfolgreich D_ϕ täuschen.

2.3.1 GAN-Trainingsalgorithmus

Heutzutage gibt es viele Varianten von GANs. Der grundlegende Algorithmus von GANs ist jedoch:

For epochs $1, \dots, N$ do:

1. Sample minibatch of size m from data: $x(1), \dots, x(m) \sim D$
2. Sample minibatch of size m of noise: $z(1), \dots, z(m) \sim p_z$
3. Take a gradient descent step on the generator parameters
4. Take a gradient ascent step on the discriminator parameters ϕ .

2.3.2 Conditional Generative Adversarial Networks (cGAN)

Ein Conditional Generative Adversarial Network (cGAN) kann unter Verwendung des gleichen Algorithmus erhalten werden, aber wenn sowohl der Generator als auch der Diskriminator durch die zusätzliche Information y konditioniert werden. y können beliebige Hilfsinformationen sein, wie z. B. Klassenspezifikationen oder Daten von anderen Modalitäten. Die Konditionierung kann erfolgen, indem y sowohl dem Diskriminator als auch dem Generator als zusätzliche Eingabeschicht zugeführt wird.

A Conditional Generative Adversarial Network (cGAN) can be obtained by using the same algorithm, but by giving the additional information y that can be any kind of auxiliary data. This will be fed to both sub-models of the network, the generator and the discriminator, as an additional input layer.

2.3.3 Pix2Pix

Insbesondere bei Bild-zu-Bild-Übersetzungsimplementierungen ist pix2pix ein weit verbreitetes Architektur von cGAN. Dieses Verfahren hat eine spezielle Architektur, die das Generator-Subnetz als U-Net-Architektur von CNNs und den Diskriminator als Patch-basiertes vollständig konvolutionelles Netz aufbaut, das eine Eingabe einer kanalweisen Verkettung der semantischen Label-Karte und des entsprechenden Bildes hat.

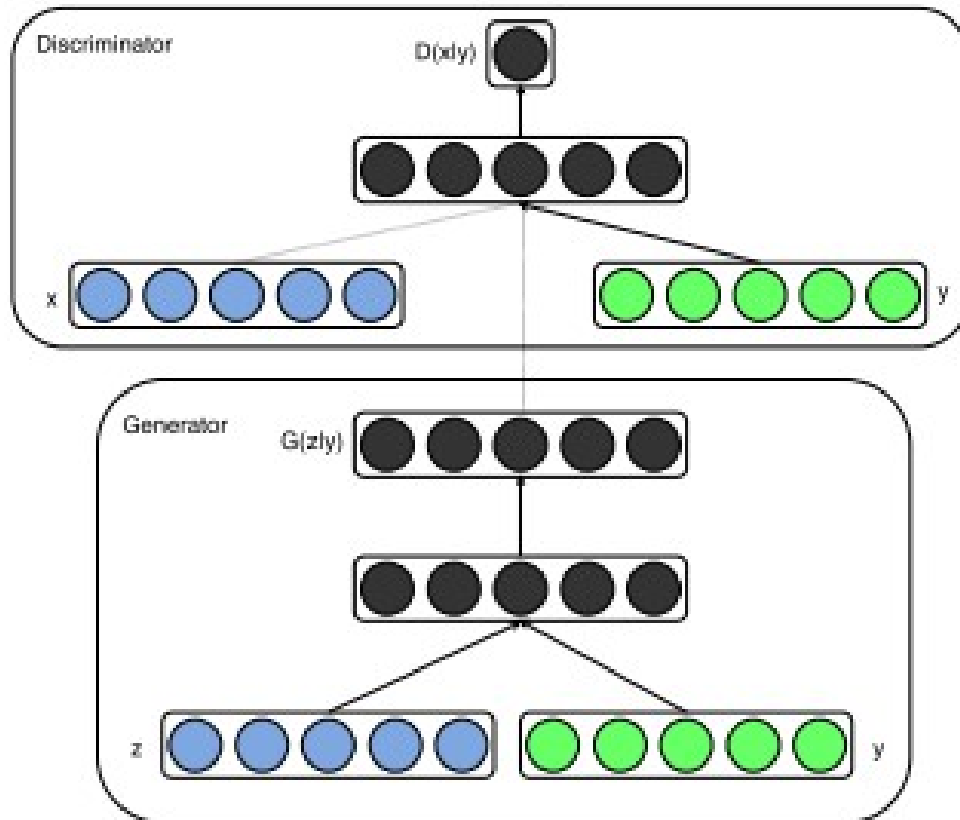


Abbildung 2.9: Die Architektur von cGAN

2.3.4 Probleme der GANs

Es gibt keinen klaren Endpunkt für die Generator- und Diskriminatorverluste, und sie würden normalerweise weiter konvergieren, ohne anzuhalten. In Ermangelung eines eindeutigen Abbruchkriteriums ist es schwierig, genau zu wissen, wann die GAN das Training beendet hat. Außerdem kann der Generator eines GAN oft Schwierigkeiten haben, eine von mehreren Arten von sich wiederholenden Mustern zu erzeugen, und würde an diesem Punkt bleiben, ohne das Diskriminatornetzwerk zu speisen, was dazu führt, dass das gesamte GAN zusammenbricht (Kollapsmodus). Es wurde jedoch eine große Menge an Forschung betrieben, um neue Architekturen, Regularisierungsschemata und Rauschstörungen zu entwickeln, um diese Probleme zu vermeiden, und neue Lösungen werden immer besser.

2 Fundamentals

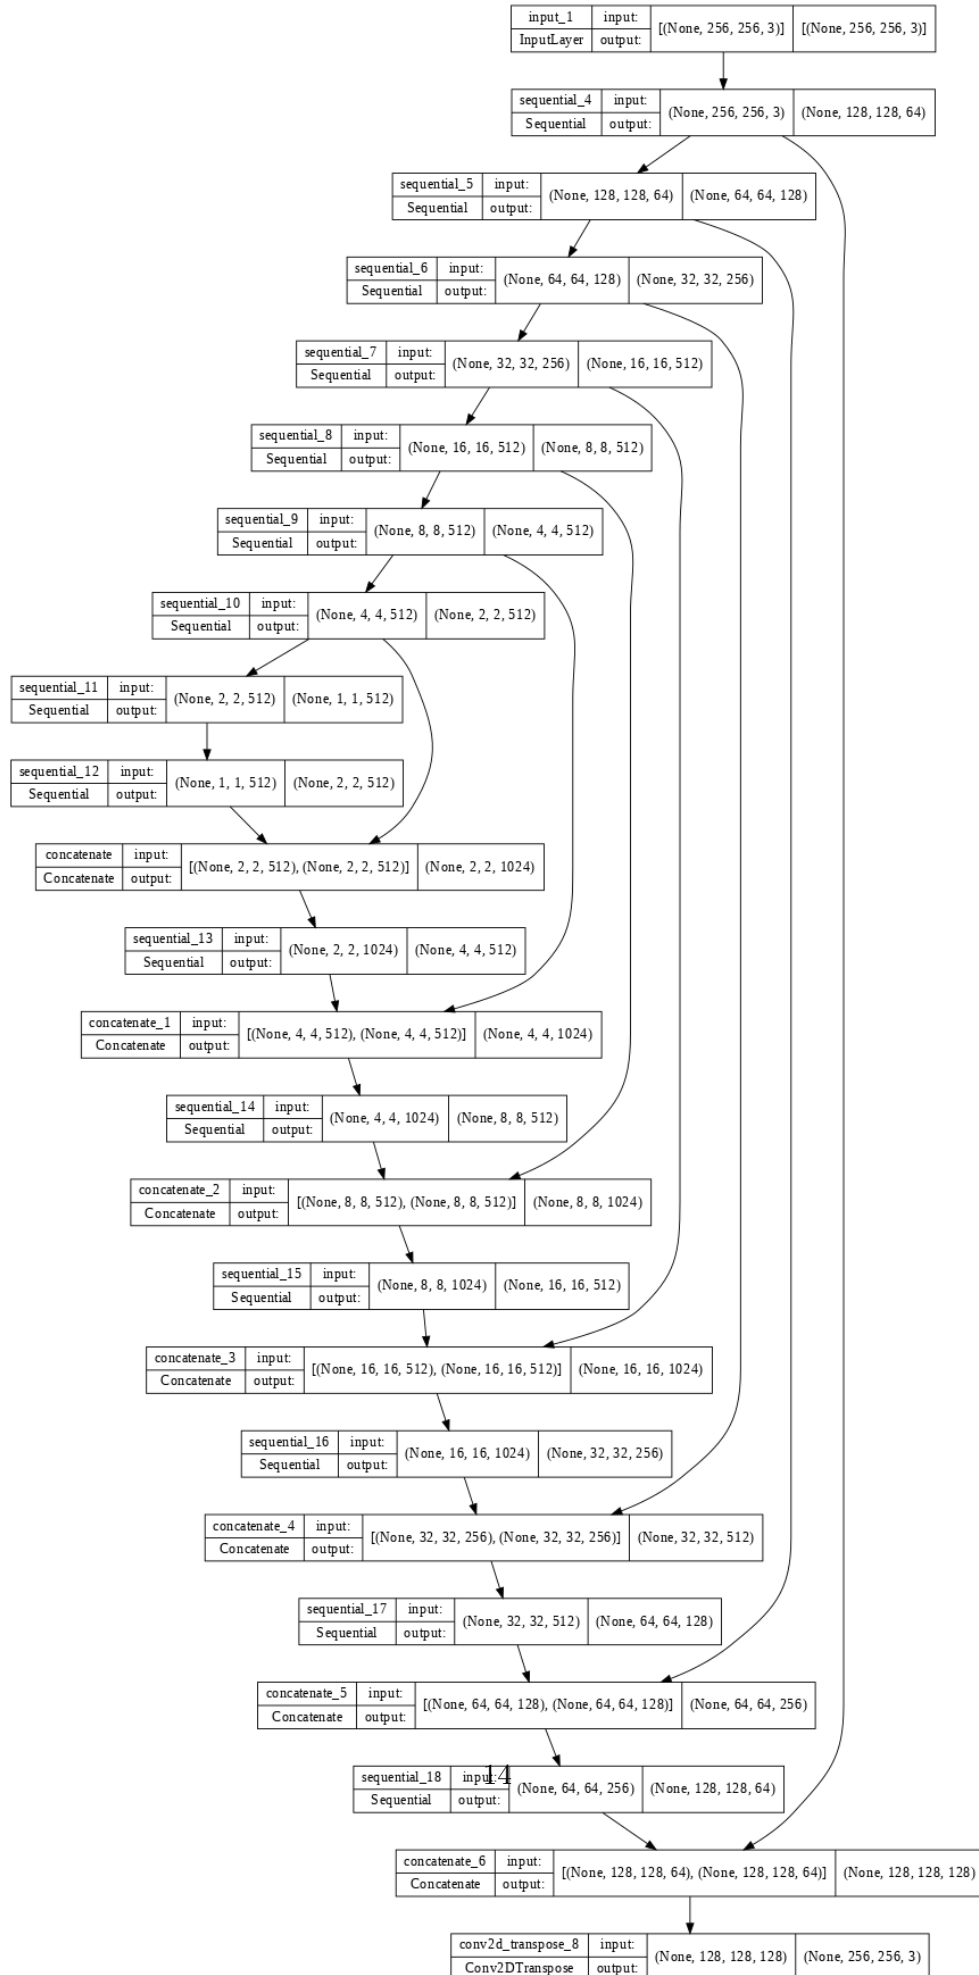


Abbildung 2.10: Die Architektur von dem Generator Netzwerk in Pix2Pix

2 Fundamentals

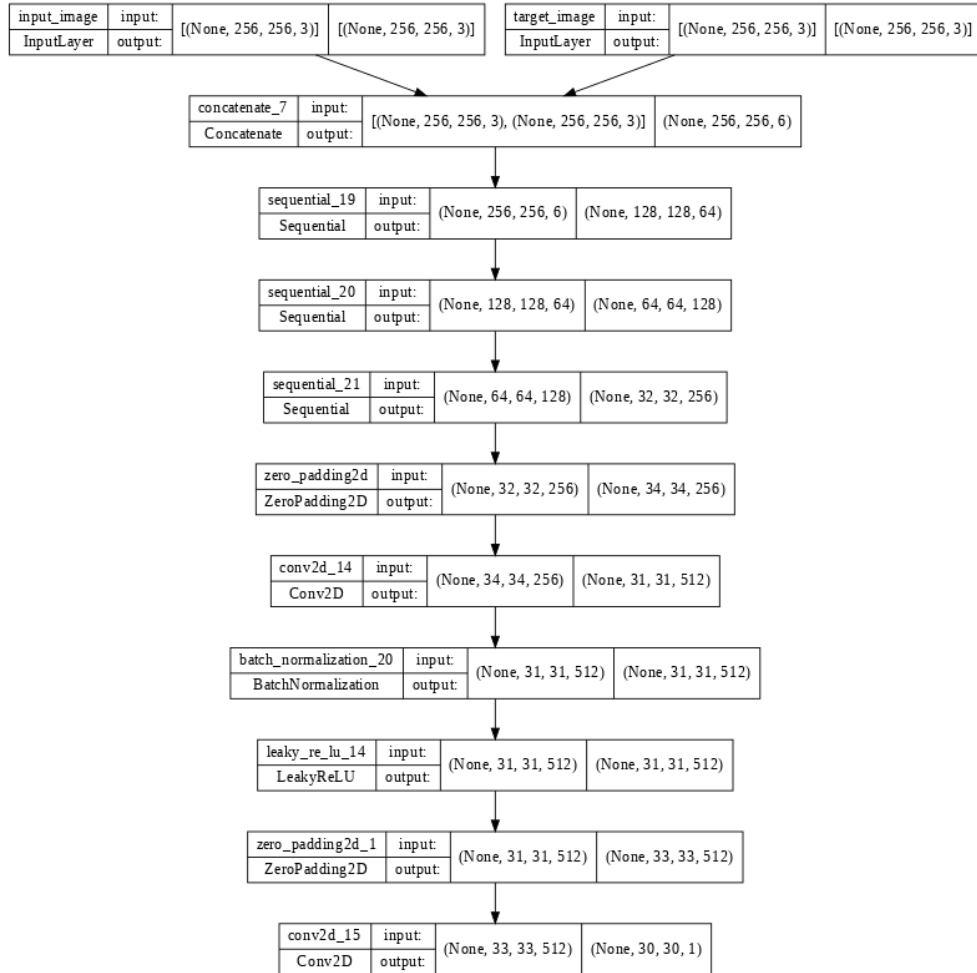


Abbildung 2.11: Die Architektur von dem Discriminator Netzwerk in Pix2Pix

3 Der Stand der Technik

GANs sind ein beeindruckendes und sich schnell entwickelndes Feld, das die Fähigkeit generativer Modelle zeigt, authentische Beispiele in vielen Problembereichen zu generieren, insbesondere bei Bild-zu-Bild-Konvertierungsaufgaben wie der Übersetzung der Bilder des Mars in ein erdähnliches Bild mit Ozeanen und Grün Landschaften, Sommerfotos in den Winter oder ein Kindergesicht in ein altes Menschengesicht und um realistische Bilder von Dingen, Szenen und Menschen zu schaffen, die selbst Menschen nicht von Fälschungen unterscheiden können. Hier sind einige Beispiele für die Verwendung von GANs in vielen verschiedenen Bereichen, einschließlich der Verwendung von GANs in früheren Sonnenforschungen:

3.1 Das Nutzen von GANs in anderen wissenschaftlichen Felder

Die Arbeit von Wangwan [2019] schlägt Modulfunktionen von Conditional Adversarial Generative Networks vor, um realistische Gesichter zu erzeugen, die einem Zielalter entsprechen, wobei die Merkmale und die Identität des Gesichts der Person im Bild erhalten bleiben. das Identity Preserving-Modul speichert die Identitätsinformationen und das IPCGAN-Framework (Conditional Identity Preserving Generative Adversarial Networks), das vom Altersklassifizierer erzwungen wird, um Gesichter vorzuschlagen, die vom Zielalter generiert wurden. Sowohl qualitative als auch quantitative Experimente zeigen, dass unsere Methode realistischere Gesichter in Bezug auf menschliche Beobachtung und Bildqualität, menschliche Identität und Altersanpassung erzeugen kann.

Dirvanauskas erstellte künstliche Bilder von menschlichen Embryozellen, die alle notwendigen Merkmale eines echten Zellbildes enthielten, um vollkommen authentische künstliche Übereinstimmungen zu schaffen, die für jede Art von Studien verwendet werden könnten, die die Verarbeitung von Embryobildern beinhalten, was vielversprechend für die Fähigkeit, neue synthetische Bilddatensätze für Forschungsbereiche zu generieren ist, in denen reale Daten nicht verfügbar sind.[Dirvanauskas D, 2019]

3.2 Verwendung von GANs und CNNs in ähnlichen Solarstudien

Eines der neuesten Papiere von Ankan Dash zeigte die Leistungsfähigkeit der Verwendung von GANs, die von Dash erstellt wurden. Es implementiert die Algorithmen Pix2PixHD und Pix2Pix, um hochauflösende Sonnenbilder zu erzeugen. Sie verwendeten Daten von 2012, 2013 und 2014 für Training und Tests.

Die Ergebnisse zeigen, dass Deep-Learning-Modelle von GANs detaillierte Bilder mit einer Auflösung von bis zu 1024 Pixel AIA0304-Bilder aus HMI-Magnetogrammen erzeugen können.

Diese Veröffentlichung kommt unserer Arbeit bei weitem am nächsten und ist die hilfreichste verwandte Arbeit, da sie auch Paare von Magnetogrammen und einen anderen Sonnenbildtyp, in ihrem Fall AIA0304, verwendet und GANs verwendet, um AIA0304-Bilder zu synthetisieren, die neuen Magnetogrammen entsprechen.

4 DataSet

Für diese Aufgabe benötigen wir Paare von Sonnenfotos. einer vom Typ AIA 1600 und der andere vom Typ HMIB. Die Fotos müssen konsistent sein. das bedeutet, dass sie in einem relativ sehr kurzen Zeitraum oder wenn möglich gleichzeitig eingenommen werden müssen. Da die Daten authentisch und konsistent sein müssen, brauchten wir dafür eine authentische Quelle. Ich habe Fotos des SDO verwendet, die in einem relativ kleinen Zeitabstand aufgenommen wurden.

4.1 Daten Suche

Zuerst habe ich auf die Datenbank zum Durchsuchen von Bildern des SDO zugegriffen, dann habe ich mit Web Scraping einen Datenrahmen erstellt, der die Anzahl, den Typ, die Zeit und die Auflösung der Bilder enthält, die an diesem Tag vom SDO aufgenommen wurden. Dann wiederum habe ich die Bilder von AIA 1600 und HMIB von jeden Tag von 10/06/2010 bis 10/06/2022 und von der Resolution 512*512 mithilfe von Web Scraping direkt aus dem SDO in mein Notebook-Verzeichnis heruntergeladen. Da, die Daten Menge sehr groß war, es war günstiger und schneller, die Daten auf die Cloud zu speichern.

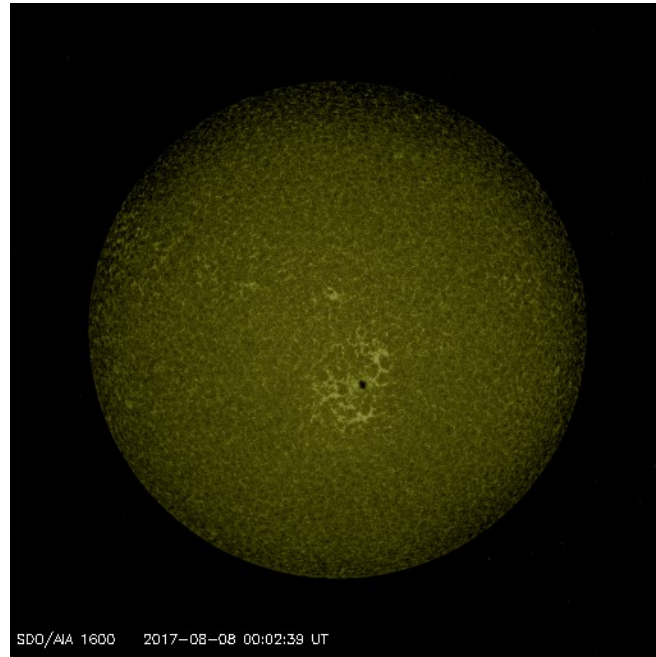


Abbildung 4.1: Foto von der Sonne- AIA1600 genommen am 08/08/2017 mit [NASA]

4.2 Daten Analyse

Leider gab es eine Inkonsistenz, obwohl die Bilder direkt vom SDO heruntergeladen wurden. Die Sonnenbilder von AIA1600 hatten ein Problem, nämlich, dass sie die Sonne aus einem kleineren Winkel abbildeten. Allerdings sah die Sonnenscheibe weiter weg aus und nahm nicht wirklich die wahre Größe der Pixel an, die sie angeblich hatte, 512*512.




Abbildung 4.2: Foto von der Sonne-am Links AIA1600 und am Rechts Magnetogram HMIB. genommen am 08/08/2017 mit [NASA]

4.3 Daten Bearbeitung

Um das Problem der Inkonsistenz der Objektgröße des Bildes zu lösen, musste ich manuell den Pixelbereich sehen, den die Sonnenscheibe in jedem Bildtyp, AIA1600 und HMIB, ausfüllte. Danach habe ich willkürlich Bildpaare aus dem Datensatz ausgewählt und sie zusammengefügt, indem ich neue Bildpaare erstellt habe, die den Bereich der Pixel des Bildes maximieren, die das beabsichtigte Objekt enthalten.

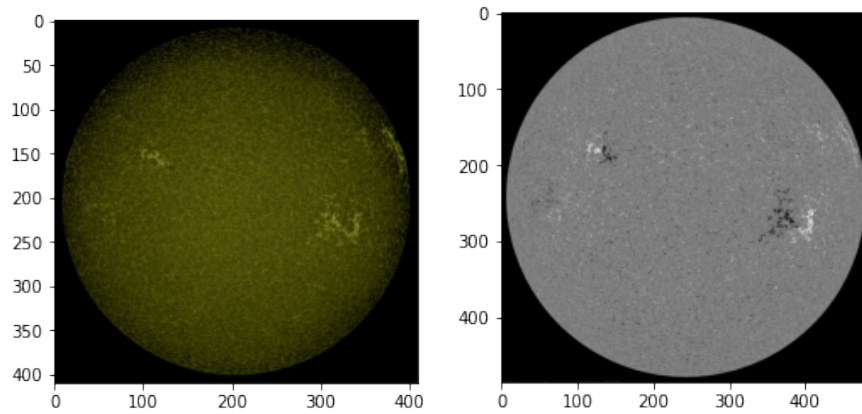


Abbildung 4.3: Foto von der Sonne mit der Größe von 256*256 jeweils-am Links AIA1600 und am Rechts Magnetogram HMIB. genommen am 01/05/2017 mit [NASA]

Da die Pix2Pix-Architektur nur Bilder der Größe $226 * 256$ als Eingabe akzeptiert, musste ich die gesamte Bildmenge des Datensatzes auf diese Größe ändern. Danach habe ich mich entschieden, beide Bilder zu einem Bild der Länge $512 * 256$ zu kombinieren. dies sollte verhindern, dass die vorverarbeitende Datenpipeline Bildpaare mit der falschen Kombination aufnimmt, da es sehr wichtig war, die Beziehung zwischen den Paaren aufrechtzuerhalten, die sich darin ähneln, dass sie in sehr kleinen Zeitintervallen aufgenommen werden. Diese Methode zum Speichern des Datensatzes erleichtert auch das Durchlaufen des Datensatzes, da sich alle Daten in einem Verzeichnis oder in einem Verzeichnisbaum der Tiefe 1 befinden, wenn sie in Stapel aufgeteilt werden.




Abbildung 4.4: Kombinierte Foto von der Sonne mit größe $512*256$ -am Links AIA1600 und am Rechts Magnetogram HMIB. genommen am 01/05/2017 mit [NASA]

Abbildungsverzeichnis

1.1	Foto von der Sonne-am Links AIA1600 und am Rechts Magnetogram HMIB. [NASA]	5
2.1	7
2.2	Ein Beispiel von einer Konvolution auf eine Stelle in Matrix	7
2.3	Ein Beispiel von eine Pooling Operation, nämlich MaxPooling	8
2.4	Ein Beispiel von eine Deconvolution Operation	9
2.5	Konvolution, pooling, Dekonvolution, und unPooling	9
2.6	eine Voll-Konvolutionale Neurale Netzwerk	10
2.7	Die Architektur von U-Net	10
2.8	Die Architektur von GAN	11
2.9	Die Architektur von cGAN	13
2.10	Die Architektur von dem Generator Netzwerk in Pix2Pix	14
2.11	Die Architektur von dem Discriminator Netzwerk in Pix2Pix	15
4.1	Foto von der Sonne- AIA1600 genommen am 08/08/2017 mit [NASA] .	19
4.2	Foto von der Sonne-am Links AIA1600 und am Rechts Magnetogram HMIB. genommen am 08/08/2017 mit [NASA]	19
4.3	Foto von der Sonne mit der Größe von 256*256 jeweils-am Links AIA1600 und am Rechts Magnetogram HMIB. genommen am 01/05/2017 mit [NASA]	20
4.4	Kominierte Foto von der Sonne mit größe 512*256 -am Links AIA1600 und am Rechts Magnetogram HMIB. genommen am 01/05/2017 mit [NASA]	21

Tabellenverzeichnis

Literaturverzeichnis

Alcoholism identification based on an alexnet transfer learning model. front psychiatry. (10:205. doi: 10.3389/fpsy.2019.00205), 2019.

G. W. Ankan Dash, Junyi Ye. URL <https://arxiv.org/pdf/2106.03814.pdf>.

R. V. D. R. S. R. H. Dirvanauskas D, Maskeliunas R. human embryo image generator based on generative adversarial networks. (10.3390/s19163578), 2019.

B. H. Hyeonwoo Noh, Seunghoon Hong. Learning deconvolution network for semantic segmentation. 2015. URL [arXiv:1505.04366](https://arxiv.org/abs/1505.04366).

NASA. Solar dynamic observatory.

O. Ronneberger, P. Fischer, and T. Brox. U-net: Convolutional networks for biomedical image segmentation. 9351:234–241, 2015. URL <http://lmb.informatik.uni-freiburg.de/Publications/2015/RFB15a>. (available on [arXiv:1505.04597](https://arxiv.org/abs/1505.04597) [cs.CV]).

J. Z. . C. G. M. Snoek. URL {jzhao3,cgmsnoek}@uva.nl.

Eidesstattliche Erklärung

Ich versichere, die von mir vorgelegte Arbeit selbständig verfasst zu haben.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder nicht veröffentlichten Arbeiten anderer entnommen sind, habe ich als entnommen kenntlich gemacht. Sämtliche Quellen und Hilfsmittel, die ich für die Arbeit benutzt habe, sind angegeben.

Die Arbeit hat mit gleichem Inhalt bzw. in wesentlichen Teilen noch keiner anderen Prüfungsbehörde vorgelegen.

Istanbul, 15. Juli 2022

Muhammed KURNASAN